

人工智能与机器学习基础

HW1-26

TA: 徐泽宇

2026 年 9 月

作业说明：本次作业共四题。请在作答时写出必要的计算过程与推导步骤；涉及手动求导的部分，请不要使用自动微分代替。

1 平方损失的偏差—方差分解

(15 pts)

我们知道，在使用相同的模型和训练方法的情况下，换一组训练数据，也大概率会得到不同的预测结果。此外，标签本身还可能带有噪声。因此在这个问题中，我们看看这些因素如何共同影响平方损失下的测试误差。

我们固定一个输入 $\mathbf{x}_0$ ，设测试标签为 $y = f_*(\mathbf{x}_0) + \epsilon$ ，其中 $\mathbb{E}[\epsilon] = 0$ 、 $\mathbb{E}[\epsilon^2] = \sigma^2$ 。用随机训练集 S 训练模型后，记它在该输入处的预测为 $Z = f_{\hat{\mathbf{w}}_S}(\mathbf{x}_0) = \hat{\mathbf{w}}_S \cdot \phi(\mathbf{x}_0)$ ， $m = \mathbb{E}_S[Z]$ 。假设 ϵ 与 S 独立，且所有随机变量均有有限二阶矩。

(a) 请补全下面的偏差—方差分解的推导：

$$\mathbb{E}_{S,\epsilon}[(y - Z)^2] = \sigma^2 + (m - f_*(\mathbf{x}_0))^2 + \text{Var}_S(Z).$$

(b) 根据上面的分解，请判断下列说法是否正确，并各用一两句话说明理由。

1. 若模型的平均预测等于真实条件均值，则期望测试误差一定为零。
2. 在测试噪声不变时，若平方偏差的增加小于预测方差的减少，则期望测试误差下降。
3. 模型的训练误差越低，其泛化表现越好。

2 平方损失下的多输出回归

(20 pts)

前面的回归模型只预测一个数值。如果我们希望同时预测多个数值，是不是必须把所有输出放在一起求解？在这个问题中，我们从平方损失出发，分析什么时候可以把多输出回归拆成多个单输出问题。

给定 N 个样本 $(\mathbf{x}_i, \mathbf{y}_i)$ ，其中 $\mathbf{y}_i \in \mathbb{R}^n$ ， y_{ij} 为第 i 个样本的第 j 个输出。采用固定特征映射 $\phi(\mathbf{x}) \in \mathbb{R}^d$ ，模型为

$$f_{\mathbf{W}}(\mathbf{x}) = \mathbf{W}^T \phi(\mathbf{x}), \quad \mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_n] \in \mathbb{R}^{d \times n}.$$

各输出的参数向量 $\mathbf{w}_j$ 可以独立选择，总平方损失为

$$L(\mathbf{W}) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^n (\mathbf{w}_j \cdot \phi(\mathbf{x}_i) - y_{ij})^2.$$

假设各单输出问题均存在最优解。本题无需计算梯度或推导闭式解。

(a) 请先写出第 j 个输出的均方误差 $L_j(\mathbf{w}_j)$ ，将 $L(\mathbf{W})$ 表示为各单输出损失之和。只改变 $\mathbf{w}_k$ 、保持其他参数不变时，哪些损失项可能变化？请说明理由。

(b) 我们能否先分别求出各个输出的最优参数，再把它们组合起来？

请证明：分别最小化各 L_j 后组合参数，与联合最小化 L 是等价的。证明须说明独立最优解的组合是联合最优解，以及联合最优解中的每列参数也分别最优。这里是否还需要假设不同输出在统计上独立？请简要说明。

(c) 现在考虑两个输出，即 $n = 2$ ，并额外要求 $\mathbf{w}_1 = \mathbf{w}_2$ ，是否仍能直接组合两个单输出问题的最优解？假设这两个问题各自的最优解唯一且不同，说明它们的损失能否同时达到各自无约束的最小值，并指出 (b) 中哪个条件不再满足。

3 线性回归：特征表示、模型训练与正则化

(40 pts)

考虑一个线性回归任务，输入为二维向量 $\mathbf{x} \in \mathbb{R}^2$ ，预测目标为实数 y 。下表给出了 6 个训练样本。在这个问题中，我们使用包含常数特征及两个原始输入特征的线性模型，常数特征排在首位：

$$\mathcal{F} = \{f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w} \cdot \phi(\mathbf{x}) : \mathbf{w} \in \mathbb{R}^3\}.$$

样本	$\mathbf{x}$	y
1	$(1, 0)^\top$	2
2	$(0, 1)^\top$	0
3	$(1, 1)^\top$	3
4	$(-1, 0)^\top$	-4
5	$(0, -1)^\top$	-2
6	$(-1, -1)^\top$	-5

记 $P = \text{diag}(0, 1, 1)$ ，它将权重向量的首个分量置零、保留其余分量。我们在平方损失中加入 L2 正则项，得到目标函数

$$J_\lambda(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\mathbf{w} \cdot \phi(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{P}\mathbf{w}\|_2^2.$$

其中 $\lambda \geq 0$ 为正则化强度，控制训练误差与权重惩罚之间的权衡。请注意，**首个分量对应截距，不参与正则化**。下面我们通过手动计算，看看梯度更新和正则化分别带来什么影响。

(a) 首先，请写出特征向量 $\phi(\mathbf{x})$ ，并按表中的样本顺序写出设计矩阵 Φ 、目标向量 $\mathbf{y}$ 及其维度。

是否存在权重向量，使 $f_{\mathbf{w}}(\mathbf{x}_i) = y_i$ 对全部六条样本成立？若存在，请求出一个这样的权重向量，记为 $\mathbf{w}_A$ ，并代回验证；若不存在，请说明理由。

(b) 请利用 (a) 中的设计矩阵和目标向量，写出目标函数的矩阵形式，再将它展开为关于 $\mathbf{w}$ 的二次型，并手动推导梯度向量。

(c) 现在取 $\lambda = 1/3$ 、 $\mathbf{w}^{(0)} = (0, 1, -1)^\top$ 、学习率 $\eta = 1/4$ 。请计算残差向量、梯度，以及进行一次全批量梯度下降后的权重向量。比较更新前后的目标函数值，看看这次更新是否使目标下降。（注意，所有参数应同时更新。）

(d) 现在，我们将 (a) 中的 $\mathbf{w}_A$ 作为 $\lambda = 0$ 时的候选模型，并与下面这个 $\lambda = 1/3$ 时的候选模型比较：

$$\mathbf{w}_B = (-1, 2, 1)^\top \quad (\lambda = 1/3).$$

本问无需重新求解最优参数。请计算两个模型的训练 MSE、 $\|P\mathbf{w}\|_2^2$ ，以及在验证集

$$V = \{((0, 0)^\top, 1), ((1, 0)^\top, 2), ((0, 1)^\top, 1)\}$$

上的 MSE。根据验证结果，你会选择哪个模型？计算验证 MSE 时，是否应该加入正则惩罚？请说明理由。

- (e) 接下来，我们进一步考虑正则化强度的影响。记训练 MSE 为 $L(\mathbf{w}) = N^{-1}\|\Phi\mathbf{w} - \mathbf{y}\|^2$ 。固定训练数据，设 $0 \leq \lambda_1 < \lambda_2$ ， $\mathbf{w}^{[1]}$ 、 $\mathbf{w}^{[2]}$ 分别为 J_{λ_1} 、 J_{λ_2} 的全局最优解。请证明

$$\|P\mathbf{w}^{[2]}\|^2 \leq \|P\mathbf{w}^{[1]}\|^2, \quad L(\mathbf{w}^{[2]}) \geq L(\mathbf{w}^{[1]}).$$

那么，增大 λ 是否一定能降低验证 MSE？请简要说明。提示：分别利用两个解的最优性，比较它们在同一个目标函数下的值。

- (f) 除了在目标中加入 L2 正则项，我们还可以在更新时对权重进行衰减。两种做法有什么联系？将不含正则项的数据损失记为 $L(\mathbf{w})$ ，则 $J_\lambda(\mathbf{w}) = L(\mathbf{w}) + \lambda\|P\mathbf{w}\|_2^2$ 。**权重衰减 (Weight Decay)** 在更新时将需衰减的旧权重乘以一个小于 1 的正因子 c 。若截距不衰减，完整权重向量的更新可写为

$$\mathbf{w}^{(t+1)} = D_c \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} L(\mathbf{w}^{(t)}), \quad D_c = \text{diag}(1, c, c).$$

对本目标函数使用普通梯度下降，取 (c) 中的 $\eta = 1/4$, $\lambda = 1/3$ ，请计算对应的 c 。请解释 D_c 的首个对角元素为何是 1，而不是 c 。

4 逻辑回归：概率建模与分类置信度

(25 pts)

逻辑回归不仅给出预测类别，还会给出属于某个类别的概率估计。在实际应用中，我们既关心“分得对不对”，也关心“给出的概率是否可靠”。下面我们用两个简单的数据集，分析分类结果、预测置信度与训练损失之间的区别。

考虑二分类任务， $x \in \mathbb{R}$ ， $y \in \{0, 1\}$ 。采用特征向量 $\phi(x) = (x)$ 和权重向量 $\mathbf{w} = (t)$ ，其中 $t \in \mathbb{R}$ 为待学习参数，模型不含截距：

$$p_t(1 | x) = \sigma(\mathbf{w} \cdot \phi(x)) = \sigma(tx), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

对训练集 $D = \{(x_i, y_i)\}_{i=1}^N$ ，假设给定输入与参数后各标签条件独立。记似然为 $\mathcal{L}_D(t)$ ，平均负对数似然为 $J_D(t) = -\frac{1}{N} \ln \mathcal{L}_D(t)$ 。

下表给出 D_A, D_B 各 8 条独立观测的频数，似然按观测逐条相乘。两者的似然和损失分别简记为 $\mathcal{L}_A, \mathcal{L}_B$ 与 J_A, J_B 。除 (d) 外，不加正则项。

特征值 x	数据集 A		数据集 B	
	$y = 0$	$y = 1$	$y = 0$	$y = 1$
-1	3	1	4	0
1	1	3	0	4

- (a) 对于表中的两个数据集，请分别写出似然 $\mathcal{L}_A(t), \mathcal{L}_B(t)$ ，并据此求出平均负对数似然 $J_A(t), J_B(t)$ 。说明为什么最大化似然等价于最小化该损失。

- (b) 对于数据集 A，请求出最优权重向量，并证明它是唯一的。对于数据集 B，求训练目标的下确界，并说明是否存在有限参数使其达到。请结合两个数据集的标签分布，解释为什么会出现这样的差异。

提示：可直接使用 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 。

- (c) 以 $1/2$ 为分类阈值，设 $t > 0, c > 1$ ，将 $\mathbf{w} = (t)$ 放大为 $c\mathbf{w} = (ct)$ 。

请证明决策边界不变，并比较放大前后在 B 上的分类错误率、真实标签的预测概率和平均负对数似然，解释三者变化的差异。

- (d) 根据前面的分析，请判断下面两种说法是否正确，并各用一两句话说明理由：

1. 在数据集 B 上，训练分类错误率为零就说明负对数似然已达到最小值，无需继续降低该目标。
2. 模型赋予训练样本真实标签的概率越来越接近 1，就能保证它在同分布测试数据上的平均负对数似然越来越低。

最后，请用一两句话解释，在 $J_B(t)$ 中加入 $\lambda \|\mathbf{w}\|_2^2 = \lambda t^2$ ($\lambda > 0$) 为什么能抑制权重无限增大；无需求导或证明最优解的唯一性。