作业二：神经网络与无监督学习

王崇安 & 刘文西

2026 年 11 月

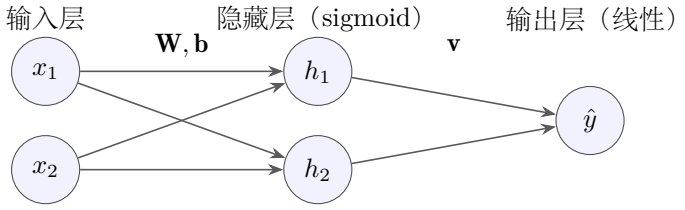
作业说明 请写出必要的推导和理由，“提示”中的结论可以直接使用，无需证明。

1 神经网络的前向传播与反向传播 （25 分）

考虑输入和隐藏层各含两个神经元、输出为标量的网络：

$$\mathbf{z} = \mathbf{W}^\top \mathbf{x} + \mathbf{b}, \qquad \mathbf{h} = \sigma(\mathbf{z}), \qquad \hat{y} = \mathbf{v}^\top \mathbf{h}, \qquad L = \tfrac{1}{2}(\hat{y} - y)^2,$$

其中 $\sigma(t) = 1/(1+e^{-t})$ 对向量逐元素作用，所有向量均为列向量。



取

$$\mathbf{x} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad \mathbf{W} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad y = 1.$$

(a)（4 分）计算 $\mathbf{z}, \mathbf{h}, \hat{y}, L$。

(b)（9 分）利用链式法则，推导并计算 $\partial L/\partial \mathbf{v}$、$\partial L/\partial \mathbf{W}$ 和 $\partial L/\partial \mathbf{b}$。先写出一般传播关系，再代入数值。

提示：$(\partial L/\partial \mathbf{W})_{ij} = \partial L/\partial W_{ij}$。

(c) (i)（3 分）证明：对任意正整数 m 和 $z_1, \ldots, z_m \in \mathbb{R}$，有 $\left|\prod_{\ell=1}^{m} \sigma'(z_\ell)\right| \le 4^{-m}$。

(ii)（7 分）固定上述输入 $\mathbf{x}$，考虑有 m 层 sigmoid 隐藏层的网络：

$$\mathbf{h}^{(0)} = \mathbf{x}, \qquad \mathbf{h}^{(\ell)} = \sigma(\mathbf{W}_\ell^\top \mathbf{h}^{(\ell-1)} + \mathbf{b}_\ell), \quad \ell = 1, \ldots, m,$$

$$\hat{y} = \mathbf{v}^\top \mathbf{h}^{(m)}, \qquad L = \tfrac{1}{2}(\hat{y} - y)^2.$$

设常数 $s, G > 0$ 与 m 无关，各层权重满足 $\|\mathbf{W}_\ell\|_2 \le s$，且 $\|(\hat{y} - y)\mathbf{v}\|_2 \le G$。

证明第一层权重的梯度满足

$$\left\| \frac{\partial L}{\partial \mathbf{W}_1} \right\|_2 \le \frac{G \|\mathbf{x}\|_2}{4} \left(\frac{s}{4}\right)^{m-1}.$$

并求使该上界在 $m \to \infty$ 时趋于零的 s 的范围。

范数说明。可直接使用以下定义与性质（矩阵与向量的尺寸须相容）：

$$\|\mathbf{a}\|_2 = \sqrt{\sum\nolimits_i a_i^2}, \qquad \|\mathbf{A}\|_2 = \max_{\|\mathbf{u}\|_2 = 1} \|\mathbf{A}\mathbf{u}\|_2,$$

$$\|\mathbf{A}\mathbf{u}\|_2 \le \|\mathbf{A}\|_2 \|\mathbf{u}\|_2, \quad \left\|\mathbf{a}\mathbf{b}^\top\right\|_2 \le \|\mathbf{a}\|_2 \|\mathbf{b}\|_2.$$

(iii)（2 分）在以 sigmoid 为激活函数的神经网络中，梯度消失主要属于表达能力限制还是优化困难？简述理由。

2 K-Means：目标下降与解的质量 （25 分）

给定样本 $x_1, \dots, x_n \in \mathbb{R}^d$，设 K 个聚类中心为 $\mu_1, \dots, \mu_K \in \mathbb{R}^d$。$z_i \in \{1, \dots, K\}$ 表示样本 x_i 所属簇的编号。记 $z = (z_1, \dots, z_n)$、$\mu = (\mu_1, \dots, \mu_K)$，K-Means 的目标为

$$J(z, \mu) = \sum_{i=1}^{n} \|x_i - \mu_{z_i}\|^2 .$$

一次迭代先按当前中心分配样本，再将每个非空新簇的中心更新为该簇的样本均值；若某簇为空，则其中心保持不变。距离并列时选编号最小的中心。记 $C_k = \{i : z_i = k\}$ 为第 k 簇的样本索引集合，上标 (t) 表示第 t 次完整迭代后的值。

(a)（6 分）给定非空簇 C_k，令 $\bar{x}_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$ 为该簇的样本均值。证明对任意中心 $u \in \mathbb{R}^d$，

$$\sum_{i \in C_k} \|x_i - \bar{x}_k\|^2 \le \sum_{i \in C_k} \|x_i - u\|^2 .$$

(b)（7 分）证明

$$J(z^{(t+1)}, \mu^{(t+1)}) \le J(z^{(t)}, \mu^{(t)}).$$

并据此说明目标值序列收敛。

(c)（6 分）取 $K = 2$，数据为

$$(-2, -1), \quad (-2, 1), \quad (2, -1), \quad (2, 1).$$

下表给出两种分簇的中心和目标值（无需重算）：

状态	两个中心	目标值
A：按左右分簇	$(-2, 0), (2, 0)$	$J_A = 4$
B：按上下分簇	$(0, -1), (0, 1)$	$J_B = 16$

证明 A、B 均为不动点（一次完整迭代后状态不变）。由此我们可以看出 K-Means 初始化对最终结果的影响。

(d)（6 分）允许中心重复或未使用，定义全局最优训练目标

$$J_K^* = \min_{\mu_1, \dots, \mu_K} \sum_i \min_{k \in \{1, \dots, K\}} \|x_i - \mu_k\|^2 .$$

证明

$$J_{K+1}^* \le J_K^*, \qquad J_n^* = 0.$$

据此说明，为什么不能仅按最小训练目标选择簇数 K？

3 K-Means++：距离、样本数与离群点 （15 分）

已选中心集合为 C，定义

$$D(x_i) = \min_{c \in C} \|x_i - c\|, \qquad P(x_i) = \frac{D(x_i)^2}{\sum_j D(x_j)^2}.$$

下列情形均假设分母为正。

(a)（8 分）假设数据由两个区域 A、B 构成。当前中心均在 A 中，A 有 m 个样本，B 有 s 个样本，并且

$$D(x)^2 \le r^2 \quad (x \in A), \qquad D(x)^2 \ge R^2 \quad (x \in B), \qquad R > r > 0.$$

写出下一中心落入 B 的精确概率，并证明下界

$$P(B) \ge \frac{sR^2}{mr^2 + sR^2}.$$

当 $s \ll m$ 时，仅有 $R \gg r$ 能否保证 $P(B)$ 接近 1？说明理由。

(b)（7 分）一维数据包含已选中心 0，以及尚未选中的 $2m+1$ 个样本：m 个位于 1，m 个位于 2，另有一个位于 $R > 2$，其中 m 为正整数。将 R 处的单个样本视为离群点。

(i)（5 分）求 D^2 抽样选中离群点的概率，并与在未选样本中均匀抽样的概率 $\dfrac{1}{2m+1}$ 比较。

(ii)（2 分）当 $R^2 \ge 5m$ 时，证明离群点被选中的概率至少为 $1/2$。

4 GMM 与 EM （35 分）

设 $x_1, \dots, x_n \in \mathbb{R}^d$，$z_i \in \{1, \dots, K\}$ 为隐含的成分编号。多元高斯密度为

$$\mathcal{N}(x \mid \mu, \Sigma) = \frac{1}{(2\pi)^{d/2}\sqrt{\det \Sigma}} \exp\left[-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right].$$

高斯混合模型为

$$p(z_i = k \mid \theta) = \pi_k, \qquad p(x_i \mid z_i = k, \theta) = \mathcal{N}(x_i \mid \mu_k, \Sigma_k).$$

其中 $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$，$\pi_k > 0$, $\sum_{k=1}^K \pi_k = 1$，Σ_k 正定。

(a)（4 分）推导当前参数 $\theta^{(t)}$ 下的责任度 $\gamma_{ik}^{(t)} = p(z_i = k \mid x_i, \theta^{(t)})$，并解释它与 K-Means 硬分配的区别。

(b)（13 分）固定 E 步得到的责任度。已知 M 步最大化

$$Q(\theta \mid \theta^{(t)}) = \sum_{i,k} \gamma_{ik}^{(t)} \log p(x_i, z_i = k \mid \theta).$$

记 $N_k^{(t)} = \sum_i \gamma_{ik}^{(t)}$。推导混合权重 $\pi_k^{(t+1)}$、均值 $\mu_k^{(t+1)}$ 和一般协方差 $\Sigma_k^{(t+1)}$ 的更新公式。用样本、责任度及 $N_k^{(t)}$ 表示结果；可假设更新所得协方差正定。

提示。对于对称正定矩阵 A、固定对称矩阵 B 和向量 u，有

$$u^\top A u = \operatorname{tr}(A u u^\top),$$
$$\nabla_A \log\det A = A^{-1}, \qquad \nabla_A \operatorname{tr}(AB) = B.$$

(c)（8 分）观测对数似然为

$$\ell(\theta) = \sum_i \log p(x_i \mid \theta) = \sum_i \log \sum_k p(x_i, z_i = k \mid \theta).$$

由于对数内含有求和，直接最大化上述似然较为困难。为此，对每个样本引入成分编号上的辅助分布 q_i，满足 $q_i(k) > 0$、$\sum_k q_i(k) = 1$，定义证据下界（ELBO）

$$\mathcal{L}(q, \theta) = \sum_{i,k} q_i(k) \log \frac{p(x_i, z_i = k \mid \theta)}{q_i(k)}.$$

证明 $\ell(\theta) \geq \mathcal{L}(q, \theta)$，并证明取等当且仅当 $q_i(k) = p(z_i = k \mid x_i, \theta)$ 对所有 i, k 成立。

提示：$f(x) = \log x$ 是严格凹函数，可以考虑使用 Jensen 不等式。

(d)（5 分）对于 EM 迭代，E 步取 $q_i^{(t)}(k) = \gamma_{ik}^{(t)}$，M 步按 (b) 更新参数。证明 $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$。

(e)（5 分）固定正混合权重和中心，令 $\Sigma_k = \sigma^2 I$。若 x_i 有唯一最近中心 k_*，证明当 $\sigma^2 \to 0$ 时

$$\gamma_{ik_*} \to 1, \qquad \gamma_{ik} \to 0 \quad (k \neq k_*).$$

若所有样本的最近中心均唯一，且各中心都得到样本，均值更新趋于什么？若最近中心并列，责任度是否必然趋于某一个中心的概率 1？说明理由。