

实验一：使用线性模型探究 LLM 的内部表征

编者：李欣宸

2026 年 9 月 30 日

1 背景

在前四周的课程中我们学习了线性回归和逻辑（logistic）回归。时至今日，线性模型仍然在许多简单问题中广为应用，而在大模型的研究中，回归分析也是常用工具；在该实验中，我们将会介绍**线性探测法**（linear probing）[1] 这种用于研究模型习得表征（representation）的回归分析方法，并带领大家尝试用线性模型解决 AI 科研中的实际问题。

1.1 表征

表征（representation）指机器学习系统中，信息被编码的方式。在课上我们学过，如果我们要设计线性模型，它的输入不只有原始特征（比如身高、体重等），还可以有经过构造的特征（比如 BMI），特征提取器记作 ϕ ，则我们可以将线性模型记作：

$$\hat{y} = \mathbf{w}^\top \phi(\mathbf{x}) + b$$

传统的机器学习往往依赖人们手工构造特征，而**表征学习**¹的思想就是让模型自己学习出有用的信息编码方式（比如头发长度、眼睛颜色，在人脸识别中，比起单个原始像素值更容易用于识别）。

1.2 线性探测法

一个深度学习模型往往有较多中间状态，称为激活（activation）或者隐表征（hidden representation）：

$$\mathbf{x} \rightarrow \mathbf{h}_1 \rightarrow \mathbf{h}_2 \rightarrow \cdots \rightarrow \mathbf{h}_L \rightarrow \hat{\mathbf{y}}$$

要想知道模型在推理（inference）阶段中是否使用了某种表征是困难的，但幸运的是，我们可以用**探测法**（probing）探究相关信息能否从中间状态中被解码：

$$\mathbf{h}_i \xrightarrow{\text{some model}} \mathbf{r}$$

如果我们构造出了某种模型，使得它可以在独立验证集上优于合理基线，从中间状态 $\mathbf{h}_i$ 中预测出我们关心的表征 $\mathbf{r}$ ，那么我们就可以说模型在中间状态 $\mathbf{h}_i$ 中“蕴含”了表征 $\mathbf{r}$ 。**线性探测法**就是当探测模型为线性时的特殊情况 [1]。实验中固定 LLM，仅训练探测模型；可解码不代表 LLM 在生成过程中一定使用了该信息。大家可以思考一下为什么线性表征是一个好的性质。

¹ICLR 的全称就叫 *International Conference on Learning Representations*，对，就是那个今年投稿量超过 6 万的 ICLR 2027。

2 实验内容

- 参考助教提供的代码（可选），实现线性回归与逻辑回归模型，指导在 2.1 节；
- 用线性回归模型，用 LLM 对地名的中间表征（助教已提供）预测纬度和经度，指导在 2.2 节；
- 用逻辑回归模型，用 LLM 对句子的中间表征（助教已提供）预测句子真假，指导在 2.3 节。
- 可选的附加内容，供感兴趣的同学们进一步探索，见 2.4 节。

2.1 实现线性回归与逻辑回归

代码

实验文件夹中有助教为同学们提供的基础框架，代码尽可能简洁以方便同学们理解。

- `model.py`: 定义了线性回归和逻辑回归的模型类，每个类包含了 `fit` 和 `predict` 方法；这也是本次实验核心代码所处的位置；
- `train1.py`: 关于如何使用 `model.py` 的示例文件（1 代表实验 1，即该实验 2.1）；
- `train23.py`: 后续实验的主训练脚本（2、3 代表实验 2、3）；

任务

线性回归模型：

$$\begin{aligned}\hat{\mathbf{y}} &= X\mathbf{w} + b\mathbf{1}, \quad \hat{\mathbf{y}} \in \mathbb{R}^N \\ \mathcal{L}(\mathbf{w}, b) &= \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 + \lambda_1 \|\mathbf{w}\|_1 + \lambda_2 \|\mathbf{w}\|_2^2 \\ &= \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 + \lambda_1 \sum_{j=1}^D |w_j| + \lambda_2 \sum_{j=1}^D w_j^2\end{aligned}$$

其梯度（含 ℓ_1 项时为次梯度）为：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial w_j} &= \frac{2}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{ij} + \lambda_1 \operatorname{sgn}(w_j) + 2\lambda_2 w_j, \quad j = 1, 2, \dots, D \\ \frac{\partial \mathcal{L}}{\partial b} &= \frac{2}{N} \sum_{i=1}^N (\hat{y}_i - y_i)\end{aligned}$$

逻辑回归模型，其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ ：

$$\begin{aligned}\hat{\mathbf{y}} &= \sigma(X\mathbf{w} + b\mathbf{1}), \quad \hat{\mathbf{y}} \in (0, 1)^N \\ \mathcal{L}(\mathbf{w}, b) &= -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] + \lambda_1 \|\mathbf{w}\|_1 + \lambda_2 \|\mathbf{w}\|_2^2\end{aligned}$$

其梯度（含 ℓ_1 项时为次梯度）为：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial w_j} &= \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i) x_{ij} + \lambda_1 \operatorname{sgn}(w_j) + 2\lambda_2 w_j, \quad j = 1, 2, \dots, D \\ \frac{\partial \mathcal{L}}{\partial b} &= \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)\end{aligned}$$

其中 $X \in \mathbb{R}^{N \times D}$, $\lambda_1, \lambda_2 \geq 0$, 偏置不参与正则化; 逻辑回归标签为 0 或 1。 ℓ_1 项在零点不可导, 此处取 $\text{sgn}(0) = 0$ 作为次梯度的一个选择。

你需要将以上公式用 `numpy` 库实现, 书写 `model.py` 中的 `fit` 和 `predict` 方法; 逻辑回归的 `predict` 返回标签为 1 的概率, 暂不做阈值化。

提示: 该方法可以看作一个“根据梯度更新参数——判断是否达到终止条件”的循环。终止条件需要自行设计 (如最大迭代次数、损失变化等); 含 ℓ_1 项时, 固定学习率可能在零点附近振荡。计算逻辑回归损失时, 可使用 `np.logaddexp()` 方法, 并对 `sigmoid` 作稳定计算, 避免指数溢出或 $\log 0$ 。

提交

你可以参考或者不参考助教提供的代码框架, 但请确保提交的代码中含有线性回归和逻辑回归的训练过程, 要求使用梯度下降法, 包含 ℓ_1 和 ℓ_2 正则化。(不能只有 `sklearn` 的调用)

如果使用的不是助教提供的代码框架, 请在报告中说明你的核心代码位置。

实验验收时你需要现场运行你的代码, 在此之前你的代码分数不会被最终确定。

思考题

1. 重现课件 (第 42、48 页) 中 ℓ_1 、 ℓ_2 正则化的“系数路径”, 并解释数据来源;
2. 请用案例说明 ℓ_2 正则化在回归中将很小的系数设为 0 进行特征选择是不好的 (相比 ℓ_1 正则化, 课件第 44 页);
3. 你的模型相比于 `sklearn` 的实现有拟合效果上的差异吗? (简要说明即可)

提示: 你可以在做完后两项实验后回答该题。

前两问中你都需要构造或者在网上找到合适的数据集, 以此作为思考题回答的依据。

2.2 用线性回归预测地理坐标

本实验使用的大语言模型 (LLM) 主要通过文本训练, 那它是否对我们所处的世界有空间和时间的感知呢? ICLR 2024² 的论文 [3] 就使用了线性探测法研究了 LLM 对时空的表征; 本节是该论文中其中一个实验的简化。

数据集

数据集在实验文件的 `datasets/world` 内, 包含两类文件; 数据集与论文中使用的不同, 出于实验考核的需要, 目前不考虑公布构造方式。

- `train.csv`、`valid.csv`: 训练集和验证集, 包含输入句子 (`sentence`)、国家 (`country`)、地点的纬度 (`latitude`) 和经度 (`longitude`), 单位为度, 北纬、东经为正;
- `train.layer**.npz`、`valid.layer**.npz`: 训练集和验证集的中间表征向量³, 文件名中的数字表示提取的层数 (11、23、35) (有关 `.npz` 文件格式的介绍见附录 C.1)。

²时过境迁, 投稿量至今已经翻了超过 8 倍

³国名最后一个词元 (token) 的隐表征

CSV 与对应的 `.npy` 文件逐行对齐，特征形状为 $(N, 2560)$ ，存储类型为 `float16`，训练时可转为 `float64`。此题的训练规模较小（500 个样本，验证集 130 个样本），因此你可能需要使用适当的正则化来改善模型的泛化能力；但是在真实的线性探测（linear probing）研究中，我们倾向于让数据集的规模至少大于特征的维度（比如实验 2.3 的情况）；本实验主要作为一个热身考察，实验效果比重低于实验 2.3。

任务

具体来说，我们要构造一个线性回归模型：

$$f: \mathbb{R}^{2560} \mapsto \mathbb{R}^2$$

其中，2560 是 Qwen3-4B-Base 模型中间表征向量的维度，这是一个双输出线性回归问题。由作业 1 的内容可知，在平方损失下， n 维线性回归等价于 n 个一维线性回归问题的组合，因此我们的任务是（建议使用实验 2.1 的代码）：

$$f_1: \text{feature vector} \mapsto \text{latitude}, \quad f_2: \text{feature vector} \mapsto \text{longitude}$$

为了提高模型性能，你可能需要尝试使用不同的层的中间表征向量作为输入，或者使用正则化来改善模型的泛化能力。

你可以选择其它（从 0 到 35）层中任意层的中间表征向量作为输入，但是这可能需要你自己去获取这些中间表征向量（比如通过在本科生算力平台上部署 Qwen3-4B-Base）。此为可选项，不做强制要求；但是助教为此提供教程在附录 B。

提交

- 一个 `.npz` 文件，其中 `["weights"]` 键是一个 $(2, 2560)$ 的 `np.float64` 数组，两行依次对应纬度、经度；`["bias"]` 键是一个 $(2,)$ 的 `np.float64` 数组；关于 `npz` 文件的介绍见附录 C.1；
- 一个 $[0, 35]$ 的整数，表示你的输入特征选取的层数；

最终效果分很大的比重将在一个助教未公布的测试集上进行；测试集的分布会更接近验证集的分布，与训练集的分布可能有较大差异，因此请不要过度拟合训练集。

此题的提交权重**不要求**由你使用 2.1 节手工实现的模型训练得到。

思考题

4. 对比不同层中间表征的预测效果，并分析原因；你在最终模型提交中是如何选择特征选取层次的？
5. 你在最终模型提交中是怎么选择正则化的？请说明理由；
6. 给出你的模型在验证集上的预测结果，并可视化在地图上（推荐不含国界线）；
提示：此题推荐使用 AI 工具辅助可视化程序的编写。
7. 从训练集和验证集的表现，是否能够强烈说明模型内部存在地理坐标的表征，而不是仅仅识别了输入中的国家？

对于该题可以参考原始论文 [3] 的部分结论和上一题的可视化结果；也可与按训练集国家分组的平均坐标基线比较，考察同一国家内不同地点的预测。

2.3 用逻辑回归预测句子内容真假

同样，有研究在特定模型和事实陈述数据集上发现了与句子真假相关的线性表征 [4]。本节是该论文其中一个实验的简化版。

数据集

数据集在实验文件的 `datasets/truth` 内，包含文件类型与 2.2 相同；但是，CSV 文件只包含句子 (`sentence`) 和标签 (`label`) 两列，1 表示真、0 表示假，以数据集标注为准；行序、特征形状和存储类型同上题。此处提取的中间表征向量是句子最后一个词元 (`token`) 的隐表征。

与上题不同，该题的训练规模较大 (5088 个样本，验证集 300 个样本，两个集合的真假标签均各占一半)；此题将是模型效果的主要考察内容。

任务

我们要构造一个逻辑回归模型 (建议使用实验 2.1 中的代码)，由某一层的中间表示向量预测句子的真假：

$$f: \mathbb{R}^{2560} \mapsto \{0, 1\}$$

同样的，助教只提供了训练集和验证集 11、23、35 层的中间表征向量；你同样可以根据附录 B 的教程，获取其它层的中间表征向量，或者研究自己感兴趣的句子。

提交

- 一个 `.npz` 文件，其中 `["weights"]` 键是一个 (2560,) 的 `np.float64` 数组；`["bias"]` 键是一个形状为 ()、类型为 `np.float64` 的零维数组；关于 `npz` 文件的介绍见附录 C.1；
- 一个 `[0, 35]` 的整数，表示你的输入特征选取的层数；

与上一题相同，此题的提交权重**不要求**由你使用 2.1 节手工实现的模型训练得到。

思考题

8. 仔细阅读训练集和验证集，模型的训练集和验证集存在哪些分布上的差异？你是如何应对的？
9. 你在最终模型提交中是怎么选择特征选取层次和正则化的？请说明理由。

2.4 附加内容

你可以在报告中写下思考题没有涵盖的内容 (比如在逻辑回归实验中尝试自己的句子，对训练集进行增广，或自行构造额外评估集等)，并在验收过程中向助教加以展示，讲述你的思考和认识。

附加内容可以为你在验证集效果理想而在测试集效果不理想时弥补回部分效果分；请务必确保能够讲清你的附加内容。

3 提交与给分

3.1 提交方式

目前助教正在编写实验评测平台，但是实验一是否会用到新平台仍在讨论中。具体提交方式 (使用 Blackboard 系统或新平台) 待定，请关注班级群 (微信、QQ) 通知。

提交内容包括：线性回归模型和逻辑回归模型的权重（2 份 `numpy` 数组文件⁴），特征选取的层数，实验报告（`pdf` 格式，包含思考题回答），代码。

报告要求 报告中应该包含对思考题的分析、回答和实验依据；不要求包含实验简介、代码等内容；背景铺垫、课程建议等内容建议放在附录中，原则上附录不直接记分。本次对报告长度不设严格限制，后续实验要求将按本次反馈加以调整。推荐使用 `LaTeX` 编写此实验的报告。

3.2 考核方式

- 代码（10%）：代码实现正确，验收时可运行；
- 报告规范（20%）：报告内容完整，长度合适；
特别的，出现不符合法律规定的地图可以扣掉全部报告规范分。
- 思考题（30%）：思考题回答完整，逻辑清晰，且能有适当的**理由、证据**支持；
- 模型效果（25%）：模型效果良好，且有对效果的**解释和分析**。
本实验可能计入效果的部分为 2.2 和 2.3，其中由于数据集的相关性质，**后者权重更高**。
- 实验验收（15%）：实验验收效果良好；请确保你能理解你的附加内容（若有）。

实验过程中的不诚信行为（如编造实验结果，构造 `.npz` 格式的压缩包炸弹卡爆服务器）将交由老师特殊处理。

参考文献

- [1] Guillaume Alain and Yoshua Bengio. Understanding intermediate layers using linear classifier probes, 2018. URL: <https://arxiv.org/abs/1610.01644>, arXiv:1610.01644.
- [2] Andy Ardit, Oscar Obeso, Aaquib Syed, Daniel Paleka, Nina Panickssery, Wes Gurnee, and Neel Nanda. Refusal in language models is mediated by a single direction, 2024. URL: <https://arxiv.org/abs/2406.11717>, arXiv:2406.11717.
- [3] Wes Gurnee and Max Tegmark. Language models represent space and time, 2024. URL: <https://arxiv.org/abs/2310.02207>, arXiv:2310.02207.
- [4] Samuel Marks and Max Tegmark. The geometry of truth: Emergent linear structure in large language model representations of true/false datasets, 2024. URL: <https://arxiv.org/abs/2310.06824>, arXiv:2310.06824.
- [5] Leheng Sheng, Changshuo Shen, Weixiang Zhao, Junfeng Fang, Xiaohao Liu, Zhenkai Liang, Xiang Wang, An Zhang, and Tat-Seng Chua. Alphasteer: Learning refusal steering with principled null-space constraint, 2026. URL: <https://arxiv.org/abs/2506.07022>, arXiv:2506.07022.
- [6] Alexander Matt Turner, Lisa Thiergart, Gavin Leech, David Udell, Juan J. Vazquez, Ulisse Mini, and Monte MacDiarmid. Steering language models with activation engineering, 2024. URL: <https://arxiv.org/abs/2308.10248>, arXiv:2308.10248.

⁴获取方式见 2.2

A Python 环境的配置

在运行 Python 实验的时候建议大家使用**虚拟环境** (virtual environment)。

虚拟环境的优势在于，对不同的实验或项目可以选择不同的依赖项，防止版本冲突或依赖污染。

本教程讲解如何为该课程配置一个名为 `ai26` 的 `conda` 类虚拟环境，对于其他工具 (`venv`、`uv`)，可以问 AI 或查询助教。

A.1 安装 Miniforge

Miniforge 是 `conda-forge` 社区维护的 Python 发行版，默认使用 `conda-forge` 软件源；Miniconda 和 Anaconda 的使用方法类似。

1. 如果你已经安装了 Anaconda 或 Miniconda，跳过该教程；
2. 在中科大镜像站下载 Miniforge 的最新版安装包；
3. 按照以上链接的指导，配置好 `.condarc` 文件。

A.2 创建虚拟环境

在安装完 Miniforge 后，打开终端（Windows 可使用 Miniforge Prompt）。若提示符前带有 `(base)`，表示当前处于 `base` 环境中；没有该提示不一定表示安装失败。若无法使用 `conda` 命令，请按安装提示初始化终端并重新打开。

常用的 `conda` 命令有：

```
conda create -n ai26 python=3.12 # 创建名为 ai26 的虚拟环境，Python 为 3.12
conda activate ai26 # 激活虚拟环境 ai26
conda deactivate # 退出当前虚拟环境（若在 base 中执行，则退出 base）
conda env list # 查看当前所有虚拟环境
conda remove -n ai26 --all # 删除虚拟环境 ai26
```

当你在终端中看到 `(ai26)` 的提示符时，说明你已经成功进入了虚拟环境，此时你可以用正常的 `pip` 或者 `uv pip` 安装依赖包了。

```
python -m pip install numpy pandas scikit-learn matplotlib
# 或在课程仓库根目录安装全部基础依赖：
python -m pip install -r requirements.txt
```

特别的，`jupyter` 包包含 Jupyter Notebook/Lab 的运行环境。

A.3 使用你的虚拟环境

在 VSCode 中，若安装过 Python 插件，则打开一个 Python 文件时，你可以在右下角看到当前使用的 Python 环境，点击后可以选择。

若使用 Jupyter Notebook/Lab 调试，打开一个 `.ipynb` 文件，在右上角的 Kernel 选择中，选择你创建的虚拟环境即可；VSCode 会提示你安装 `ipykernel`，请点击安装。

也可以在终端安装 `jupyter` 包，再运行 `jupyter notebook` 或 `jupyter lab`，在浏览器中打开。

在终端中，你需要确认运行文件时已激活虚拟环境。在 `labs/lab1` 目录中，实现模型后可运行：

```
python train1.py
python train23.py world 11 results/world.npz
python train23.py truth 11 results/truth.npz
```

B 本科生算力平台的使用

在本实验的第二部分 2.2 和第三部分 2.3 中，大家可以选择在学校的本科生算力平台⁵上部署模型，获取更多层或者自定义文本中的表征向量。

助教在 `extract_intrep.py` 中提供了给定文本和层数，获取指定词元的中间表征向量的示例代码。参数 `--token-selection` 在地理任务中取 `country`（国名最后一个词元），在真假任务中取 `last`（句子最后一个非填充词元）；层号从 0 开始，提取 decoder block 输出（最终 RMSNorm 之前），不使用聊天模板。输入格式、输出位置和模型版本见实验文件中的说明；LLM 的原理远超出了本课程的范围，本教程主要旨在普及本科生算力平台的使用方法。

在人工智能领域的研究中，如何配置环境，如何自己学会一个没用过的平台，是非常重要的技能；接下来的步骤可能比较困难，大家要利用手头的 AI 工具进行学习。

B.1 准备你的账号

- 使用学校的统一身份认证，登录 本科生算力平台；
- 在顶栏的“登录集群”——“Shell”中，选择“打开”，以在浏览器中打开终端；
- （可选且建议）配置你的 SSH 登录；

本科生算力平台 SSH 登录需要双步认证，需要先在本机准备好 Google Authenticator 或者 Microsoft Authenticator 等应用；并在集群命令行中输入 `google-authenticator` 命令生成二维码；

此外，你还需要在本地生成一对 SSH 密钥，并将公钥拷贝到集群的 `~/.ssh/authorized_keys` 文件中；⁶

- 你应当能打开浏览器中的命令行或者使用 SSH 登录到集群；

B.2 配置环境

- 你现在登录进的机器（`tradmin-02`）叫登录节点，它的作用是让你管理集群上的文件；
- 集群的任务由一个叫 Slurm 的系统管理，你需要在登录节点上用 `sbatch` 等命令提交任务到计算节点上运行；
- （文件系统）你的 `~` 目录并不在登录节点上，而是存储在集群的一个文件服务器上⁷，所有登录节点、计算节点和文件服务器用 Infiniband 网络（一种高速网络）互联；

⁵本科生算力平台交流群 QQ: 950728110

⁶重要概念：SSH 密钥对、Authenticator，如何使用 `ssh` 命令指定密钥登录。

⁷所以登录节点家目录的文件随机访问速度较差

- (共享) 登录节点和计算节点的 `~` 目录是共享的, 这意味着我们可以在登录节点上配置 `conda` 环境, 然后在计算节点上使用;
- 请根据 A 配置好你的 `conda` 环境;⁸

B.3 准备好脚本和模型权重

这节主要涉及将助教提供的脚本上传到集群上, 以及在集群上下载 `Qwen3-4B-Base` 模型权重。上传可以采用两种方式: `vim` 直接打开、复制, 以及 `scp/sftp`。

下载可使用 Hugging Face 的 `hf download` 命令; 在上节配置的 `conda` 环境中, 安装提取脚本需要的依赖:

```
python -m pip install torch transformers huggingface_hub
hf download Qwen/Qwen3-4B-Base --local-dir ~/models/Qwen3-4B-Base
```

这一部分留待大家自己探索, 以下为参考的可以提供给 AI 的问题:

如何下载 Hugging Face 的指定模型权重到本地指定目录?

`scp` 是干什么的? 列举一些常用的 `scp` 命令示例。

`sftp` 的主要语法?

如何使用 `hf-mirror` 加速 Hugging Face 模型的下载?

下载 ModelScope 上的模型权重的命令?

B.4 提交任务

B.4.1 Slurm 常见命令

- `sbatch <script.sbatch>`: 提交作业脚本;
- `squeue -u $USER`: 查看当前用户的作业队列;
- `srun --jobid=xxx --pty bash`: 进入计算节点的 `bash`;
- `scancel <jobid>`: 取消作业。

B.4.2 Slurm 脚本的格式

```
#!/bin/bash
#SBATCH --job-name=<your-job-name>
#SBATCH --output=%x_%j.out
#SBATCH --error=%x_%j.err
#SBATCH --partition=Students
#SBATCH --qos=qos_stu_default
#SBATCH --gres=gpu:1
#SBATCH --cpus-per-task=4
#SBATCH --mem=16G
#SBATCH --time=4:00:00
```

⁸在集群中下载文件可以使用 `wget`、`curl` 等命令。

```

set -euo pipefail

cd ~/repo/USTC-AI3002-26fall/labs/lab1

# 激活 conda 环境
set +u
source ~/miniforge3/etc/profile.d/conda.sh
conda activate ai26
set -u

# 提取第 12 层表征, 输出为 train.layer12.npy
python extract_intrep.py --model_dir ~/models/Qwen3-4B-Base \
    --input datasets/world/train.csv --layer 12 \
    --token-selection country

```

Slurm 作业脚本可以看作一个包含资源申请指令的 bash 脚本，注释中指定了作业的名称、输出文件、错误文件、分区、资源需求等信息。

请按实际上传位置修改脚本中的路径，复制时去掉代码整体缩进；日志默认写入提交作业时所在的目录。默认分区为 **Students**，QoS 为 **qos_stu_default**，资源上限以平台当前规定为准，同学们可以为该课申请更多资源，具体参考申请管理。

C FAQ

C.1 npy 和 npz 文件格式

.npy 和 .npz 是我们在使用 NumPy 过程中常用的数据交换格式；

.npy 文件用于存储单个 NumPy 数组，包含数组的形状、数据类型 (dtype)，内存顺序，文件格式版本；不包含数组名等信息。

.npz 文件本质是若干个 .npy 文件的 ZIP 归档 (np.savez 不压缩，np.savez_compressed 压缩)，通常用于存储多个 NumPy 数组；.npz 文件中每个数组都有一个对应的键 (key)，可以通过键访问对应的数组。

下面提供一些参考用法：

```

import numpy as np
X = np.load("i_dont_have_a.npy", allow_pickle=False).astype(np.float64)
# W、b 为训练得到的权重和偏置：
np.savez("weights.npz", weights=np.asarray(W, dtype=np.float64),
        bias=np.asarray(b, dtype=np.float64))
with np.load("weights.npz", allow_pickle=False) as data:
    W, b = data["weights"], data["bias"]
np.save("would_you_be_my.npy", X)

```

C.2 交互式和非交互式的 Python 使用方式

在机器学习实验中，我们有两种常见的使用 Python 的方式：

- **非交互式**：将各种方法封装在若干个 Python 文件中，之后训练的时候直接在命令行中调用参数，如：

```
python train.py --input <input> --output <output>
```

在集群（如本科生算力平台）上，推荐通过作业脚本使用这种方法；它适用于长时间或者需要大量使用的任务。

- **交互式**：使用 Notebook 或者交互式 Python 解释器（如 IPython）；它适用于调试、可视化和快速实验。

D 线性……然后呢？

线性表征意味着相关信息可以由简单的线性模型解码。在部分模型和任务中，研究者进一步发现，向激活中加入特定方向的向量，可以影响模型的输出；这种方法称为**激活引导**（activation steering）[6]。例如，若通过实验找到了能影响文本情绪的方向 $\mathbf{v}$ ，可以在某一层施加干预：

$$\mathbf{h}'_i = \mathbf{h}_i + \alpha \mathbf{v}.$$

调整 α 的大小和正负，可能改变生成文本的情绪倾向。但**线性可解码并不自动保证干预有效**，方向、层次和强度都需要另行验证。

类似地，有研究在特定模型中发现了与拒绝行为相关的方向 [2]，并通过学习引导向量增强安全性 [5]；其效果和对正常任务的影响也需要实验评估。

E 关于 Max Tegmark 的介绍

我们的两个线性探测实验参考的论文，均出自 Max Tegmark 的研究团队。Max Tegmark 是麻省理工学院（MIT）的物理学家，方向由宇宙学转向人工智能。关于他的个人经历，可以参考他的个人主页 <https://physics.mit.edu/faculty/max-tegmark/>。

Max Tegmark 认为，人工智能的研究是人类文明的关键问题之一，他在 2017 年出版了《生命 3.0：人工智能时代的人类》（Life 3.0: Being Human in the Age of Artificial Intelligence）一书，书中提出了“生命 1.0、2.0、3.0”的概念，并对人工智能的发展进行了深入探讨。

助教推荐感兴趣的同学阅读该书，图书馆链接。