实验二：神经网络与无监督聚类

刘文西 & 王崇安

2026 年秋季学期

本实验包含两题：第一题研究神经网络的拟合与梯度传播，第二题比较无监督聚类方法。请补全指定代码，完成实验，并提交一份覆盖两题的 PDF 报告，报告格式自定。两题各 50 分，总分 100 分。具体评分依据见各题的“评分依据”部分。

开始实验前，请打开与本文档同目录的 `README.md` 完成环境配置，并阅读各题的代码说明。CPU、CUDA、107 平台配置和运行命令均见 README。最终只需提交报告、三个代码文件和 `clusters.npy`，具体清单见“提交”一节。实际环境、运行命令和关键配置应在报告中记录；完整配置文件、日志和原始结果无需额外上传，请在本地保留至验收结束。

目录

1 第一题：神经网络的拟合与梯度传播 **2**

2 第二题：无监督聚类 **5**

3 提交 **8**

A 推荐的聚类评价指标 **9**

1 第一题：神经网络的拟合与梯度传播

本题共两项实验，内容为比较分析网络结构、训练预算、激活函数和学习率对拟合结果及梯度传播的影响。同学们需要补全 MLP 与训练更新代码，完成给定的八组训练，并结合结果回答分析题。本题评价实现、实验记录和分析，不按拟合误差排名计分。

1.1 代码补全

代码位于 `code/q1_neural_network/`，请完成以下内容：

- `models.py`：构造 MLP 并实现前向计算；
- `train.py`：完成梯度清零、前向计算、loss 计算、反向传播和参数更新。

请大家用 PyTorch 实现相应功能，具体要求见对应源码注释，其余训练、日志、可视化、自检代码已提供，可以直接使用，具体说明见 README.md。

1.2 实验设置与结果

两项实验均使用给定的数据与初值。每项实验包含 A、B、C、D 四组设置；先完成代码补全并自检，再运行全部配置。

1.2.1 实验 A：模型拟合

拟合目标为 $[-1.5, 1.5]^2$ 上的无噪声双峰函数

$$f(x_1, x_2) = \sum_{c \in \{-0.65,\, 0.65\}} \max\left(0, 1 - \frac{|x_1 - c| + |x_2|}{0.6}\right).$$

使用课程提供的 1024 个固定训练点，在 65×65 的网格上观察整个二维区域的拟合效果。

四组均使用 ReLU 隐藏层、线性输出、平均 MSE 和 Adam，学习率固定为 0.01，batch size 为 1024。A、B 共用初值；实验的网络结构与更新预算如下：

设置	隐藏层宽度	参数量	更新次数
A：浅层基线	[16]	65	3000
B：浅层多训练	[16]	65	9000
C：浅层加宽	[64]	257	3000
D：两隐藏层	[8, 4]	65	3000

结果要求 提交四组网格 MSE 表、训练 MSE 曲线，以及目标函数与四组预测的 $x_2 = 0$ 截面对比图。根据图表简要概括各组在整体误差、收敛过程和截面拟合上的主要差异。结果部分描述直接观察到的差异，原因与结论边界在分析题中讨论。

1.2.2 实验 B：梯度消失

拟合目标为 $[-1, 1]^2$ 上的线性函数 $y = x_1 + 0.5x_2$，使用课程提供的另一组 1024 个固定训练点。

四组均使用线性输出、平均 MSE 和 SGD，batch size 为 1024，训练 1000 次更新。各组设置如下：

设置	隐藏层	激活	学习率
A：较浅 Sigmoid	2 层，每层 32 单元	Sigmoid	0.05
B：较深 Sigmoid	8 层，每层 32 单元	Sigmoid	0.05
C：较深 ReLU	8 层，每层 32 单元	ReLU	0.05
D：提高学习率	8 层，每层 32 单元	Sigmoid	0.1

B、C、D 共用相同的 Linear 初值，各组学习率保持不变。A/B 比较深度，B/C 比较激活，B/D 比较学习率。

结果要求 提交四组网格 MSE 表、训练 MSE 曲线，以及训练前后逐层相对梯度图。根据图表简要概括各组在训练效果和梯度层间分布上的主要差异。结果部分描述直接观察到的差异，原因与干预效果在分析题中讨论。

提示: 工具使用固定的 128 个样本。设第 ℓ 个隐藏层激活前的 Linear 输出 $z_\ell \in \mathbb{R}^{B\times d_\ell}$，按以下指标可视化：

$$\mathrm{RMS}_\ell = \sqrt{\frac{1}{Bd_\ell}\sum_{b=1}^{B}\sum_{j=1}^{d_\ell}\left(\frac{\partial L}{\partial z_{\ell,bj}}\right)^2}, \qquad \rho_\ell = \frac{\mathrm{RMS}_\ell}{\mathrm{RMS}_{\mathrm{out}}}.$$

L 为这批样本的平均 MSE，$\mathrm{RMS}_{\mathrm{out}}$ 以相同方式对 $\partial L/\partial \hat{y} \in \mathbb{R}^{B\times 1}$ 计算。RMS_ℓ 同时对 batch 维和神经元维归约，表示该层单个梯度分量的典型大小；ρ_ℓ 表示它相对于输出端单个梯度分量 RMS 的大小。图中若越靠近输入端的层梯度越弱，表示反向传播信号向前层衰减。

1.3 分析题

1. 实验 A

   (a) **实际拟合差异：** 比较 A、D 的网格 MSE 和截面图，哪组拟合更好？MSE 的绝对数值看起来较小，是否足以说明拟合良好？结合截面图解释。

   (b) **结构与目标：** 为什么两隐藏层可能更适合本题？尝试用 ReLU 和线性运算（含偏置）表示目标函数，说明各层的计算。
   提示： 记 $r(t) = \mathrm{ReLU}(t) = \max(0, t)$，有 $|t| = r(t) + r(-t)$。可先处理一个峰，再组合两个峰。

   (c) **改进效果与代价：** 比较 B、C 相对 A 的改善及增加的成本。本题中哪种改动更有效？为什么？

2. 实验 B

   (a) **训练困难的证据：** 比较 A、B，结合结果分析哪组存在更明显的梯度消失。仅凭损失下降缓慢能否判断梯度消失？为什么？

   (b) **更换激活的效果：** 比较 B、C，更换 ReLU 后，梯度与拟合有何变化？简要解释原因。

   (c) **提高学习率的作用：** 比较 B、D，本次提高学习率是否有效？学习率直接改变梯度还是更新幅度？两组在初始参数相同时，梯度是否相同？

评分依据

内容	分值	备注
代码补全	10	模型构造与前向 5 分；损失及训练更新 5 分。
实验 A 结果	5	
实验 A 分析	10	(a) 3 分；(b) 4 分；(c) 3 分。
实验 B 结果	5	
实验 B 分析	10	(a) 4 分；(b) 3 分；(c) 3 分。
实验验收	10	主要考察对关键代码、实验结果、分析题的理解和思考。

结果部分评价实验是否正确执行、记录与图表是否完整可信；分析部分评价解释与推理。运行结果与预期不同时，应如实记录并依据证据分析。

允许使用 AI 辅助，但应核对代码与结果，并能解释报告中的内容。

2 第二题：无监督聚类

2.1 实验目标

本题是一个空间聚类问题，使用不含类别标签的特征向量，比较 k-means++ 初始化的 KMeans 与对角协方差高斯混合模型（GMM）。请补全聚类算法与评价函数，比较方法、聚类数量和随机初始化的影响，再根据无监督证据选择最终方案。全部样本均须参与聚类。

2.2 代码补全

代码位于 `code/q2_clustering/`，请在 `submission.py` 中补全以下八个函数：

- 五个算法函数：K-Means++ 初始化、样本分配、中心更新、GMM E 步和 M 步；
- 三个评价函数：轮廓系数（Silhouette）、Calinski–Harabasz（CH）和 Davies–Bouldin（DB）。

具体接口见代码注释；自检和运行命令见与本文档同目录的 `README.md` 中“第二题：无监督聚类”一节。

算法要求 KMeans 与 GMM 的算法原理和更新步骤参照课程 PPT，具体实现要求见函数注释。本题 GMM 固定使用对角协方差，**M 步更新的每一维方差都须加上正的正则项 `reg_covar`**，以避免协方差退化和数值不稳定。

2.3 实验设置与结果

数据与约束 数据文件 `code/q2_clustering/data/features.npz` 只包含匿名特征矩阵 X：

$$X \in \mathbb{R}^{56000\times 512}, \qquad \text{dtype} = \texttt{float32}.$$

每一行对应一个样本。全部发布样本参与拟合，不再按比例切分。本实验不提供真实标签，也不得使用真实标签进行预处理、初始化、拟合、选参、评价指标计算或最终结果选择。

实验设置 两种方法均须完成，并使用相同的候选 K 和随机种子进行比较。请根据实验目的和运行预算选择配置，满足以下要求：

- 选择至少两个不同的 K，且每个 K 满足 $5 \le K \le 30$；
- 使用至少两个不同的随机种子；
- 记录每个方法的 K、随机种子及对应结果；默认配置中的八个 K 可调整，但须满足上述最低要求；
- 全部样本参与每次拟合，并记录实际使用的设备、预处理、算法参数和输出状态。

最终结果会参与教师侧性能评价。可在满足基本要求后增加候选；选择依据应来自无监督指标、跨种子表现和簇结构，并由本人实验记录支持。

结果要求 报告中建议使用轮廓系数（Silhouette）、CH 和 DB，但不要求全部使用，也可以选用其他无监督指标。无论选用哪些指标，都应说明选择理由、衡量的性质及其局限。可结合分区稳定性 ARI、簇大小、极小簇数量、目标函数、对数似然和运行时间分析。Silhouette 和 CH 越大越好，DB

越小越好；不同指标可能给出不同结论。KMeans 的惯性与 GMM 的平均观测对数似然不是同一个训练目标，不能直接比较数值大小。评价时应明确拟合空间、评价空间、抽样范围和随机种子。各指标的定义、方向和使用边界见附录 A。

报告中至少记录：

- 环境与设备（CPU 或 GPU）、Python/PyTorch 及主要依赖版本；
- 两种方法实际使用的 K、随机种子、初始化次数、迭代上限、收敛设置和预处理；
- 各候选方案的主要指标、跨种子均值或波动、簇大小及失败或异常情况；
- 最终方法和 K 的选择依据、最终输出文件以及 `extras.py check-output` 的核验结果。

最终选择 框架仍会计算三个必做评价函数的结果，报告无需逐项展示。

正式输出的主指标由 `selection_metric` 指定，当前框架支持 Silhouette、CH 和 DB，默认为 Silhouette。框架先在所有计划种子均成功、主指标有效且实际簇数符合要求的候选组中，按跨种子均值选择方法和 K；Silhouette/CH 越大越好，DB 越小越好。指标在 10^{-6} 内并列时，优先较小 K，再优先 KMeans。在选中组内，按训练目标选择代表运行（KMeans 惯性最小，GMM 平均对数似然最大），数值并列时选较小 seed。报告应说明主指标的选择及其局限，并结合其它指标分析。若要改用另一主指标，应通过评价回放输出到新目录；当前框架没有手动指定候选的正式导出入口。

可选探索 完成上述基本任务后，可以尝试更多 K、标准化或其他无监督方法，并分析其特点和适用条件。拓展方法不替代 KMeans 和 GMM 两条必做流程，也不改变正式输出协议；如在报告中展示拓展结果，应说明方法、配置和参数，相关代码和可复现实验记录在本地保留至验收结束，无需额外上传。

2.4 分析题

1. **T1：为什么选择这个聚类方案？**说明最终选择的方法和 K，结合无监督评价指标及实验结果解释选择依据，并与其他候选方案进行必要比较。
2. **T2：为什么会出现这个实验现象？**从本人实验中选择一个现象（例如方法差异、随机性影响、指标不一致或预处理效果），结合结果和算法原理分析可能原因，并说明解释的适用范围和局限。结果稳定或没有改善也可以作为分析对象。

评分依据

本题共 50 分，其中验收 10 分，其余 40 分由代码、实验与报告、最终 performance 三项组成。

内容	分值	评分依据
代码补全	10 分	正确实现五个算法函数与三个评价函数，即可拿满分。
实验与报告	20 分	KMeans 与 GMM 使用相同的至少两个合规 K，每个 K 至少两个随机种子，完成全量对比实验；完整记录设置和结果，提交合规的最终输出，并在报告中回答 T1/T2，即可拿满分。
最终 performance	10 分	最终提交结果合规且多数票 ACC 达到 99.5%，即可拿满分；低于门槛的折扣规则见下文。
实验验收	10 分	围绕本人代码和报告提问；能结合具体实现或实验结果，说明所问的代码逻辑、指标与方案的选择理由或实验现象及其可能原因，回答完整且合理，即可拿满分。

教师侧性能评价 真实标签 y_i 仅在教师侧使用。教师对每个簇独立取其最多标签计数：

$$\mathrm{ACC} = \frac{1}{N} \sum_{q \in \mathcal{Q}} \max_{\ell} \left| \{ i : c_i = q,\ y_i = \ell \} \right| .$$

一个簇只能对应一个标签，但多个簇可以对应同一标签；不做 Hungarian 一一匹配。纯簇拆分不会被直接惩罚，高 ACC 也不能单独确定真实类别数。

正式输出合规且**原始 ACC** $\geq 99.5\%$ **（即** ≥ 0.995**）时，performance 得满分 10 分**。低于该门槛时，根据 ACC 百分比对本项满分打折，具体折扣规则另行公布；门槛比较使用未四舍五入的原始 ACC。本项只评价唯一正式结果，未达到满分门槛不直接降低其他项已完成要求的得分。

3 提交

最终只需提交一份覆盖两题的 PDF 报告、三个代码文件和第二题的最终 `clusters.npy`(可以通过 `extras.py` 中 check-output 功能检查数据格式)。

提交文件 最终的提交文件结构如下:

```
submit/
├── report.pdf
└── code/
    ├── q1_neural_network/
    │   ├── models.py
    │   └── train.py
    ├── q2_clustering/
    │   └── submission.py
    └── data/
        └── clusters.npy
```

无需上传原始特征数据 `features.npz` 或其他原始输出。

本地保留与验收 原始输出无需上传, 请在本地保留至验收结束: 第一题两项实验共八组的指标、训练记录、图表、预测、模型权重和梯度诊断; 第二题完整输出目录, 以及实际运行的代码、配置和日志。两题的软件环境、运行命令、自检和输出核验记录也请一并保留。

实验报告 将两题的结果、分析题回答和必要的实验记录整理成统一报告 `report.pdf`。
第一部分需要包含:

- 实验 A、B 的结果表格、图形和简要观察;
- 实验 A、B 的分析题回答, 分析题的回答可以引用前文的结果, 尽量避免重复描述。

第二部分需要包含:

- 两种方法的实测比较
- 最终选择依据和两道分析题的回答

报告应围绕实验结果和分析题作答, 避免重复题面、粘贴大量代码或完整日志。**过长的报告可能会影响最终的评分, 请大家注意控制报告篇幅**。

A 推荐的聚类评价指标

建议结合相互补充的指标解释聚类结果。报告中推荐使用轮廓系数、CH 和 DB，但不要求全部使用，也可以选用其他无监督指标；无论选用哪些指标，都应说明选择理由、衡量的性质及其局限，并在统一口径下比较。下表解释各诊断指标的含义。框架仍计算三个必做评价函数的结果，并按配置的主指标选择正式输出；报告无需逐项展示。↑ 表示越大越好，↓ 表示越小越好；表格中可将**同一比较口径下、当前候选中的最优值加粗**，并标出并列值。数值最优不等于统计上显著更好，也不自动证明恢复了隐藏类别。

表 1: 不需要真实标签的推荐诊断指标

指标	方向	衡量内容	使用边界
目标函数 J（惯性）	↓	样本到所属簇中心的平方距离总和	增加 K 通常降低目标值；宜结合下降幅度，不宜仅取最小值选 K。
轮廓系数	↑	同簇的紧密程度与最近其他簇的分离程度	范围为 $[-1, 1]$；抽样计算时需报告抽样口径及小簇覆盖情况。
CH 指数	↑	经自由度校正的簇间离散度与簇内离散度之比	偏好紧密、分离的簇；与惯性共享部分信息，不能视为完全独立的证据。
DB 指数	↓	各簇与最易混淆簇的相对散布程度	以簇中心和平均距离描述结构，不适合所有形状的簇。
分区稳定性 ARI	↑	不同随机初始化或重复实验产生的分区一致性	比较的两个输入均为预测簇编号；高稳定性不等于隐藏标签上的高准确率。

簇大小、极小簇数量和运行时间也值得报告，但它们没有适用于所有任务的单一最优方向。不同指标的量纲、含义和偏好不同，建议分别解释其证据。

A.1 目标函数与轮廓系数

设第 i 个样本为 x_i，预测簇编号为 c_i，所属簇中心为 μ_{c_i}。KMeans 的目标函数为

$$J = \sum_{i=1}^{N} \|x_i - \mu_{c_i}\|_2^2.$$

在相同数据和距离空间中，较小的 J 表示更小的簇内平方距离。全局最优目标值随 K 增加不会上升；独立拟合的 KMeans 可能停在不同局部解，因此实测结果不保证严格单调。

GMM–EM 优化的是观测数据对数似然，不是 J。对 GMM 的最终硬分区也可计算簇内平方距离作为几何诊断，但不能将其当作 EM 的训练目标或停止依据。两条流程的硬分区均可用于下述内部指标和预测分区稳定性比较，计算空间和抽样口径须一致。

对样本 i，a_i 为它到同簇其余样本的平均距离；分别计算它到每个其他簇中样本的平均距离，取最小值作为 b_i。这里的 b_i 是到其他簇的**平均距离**，并非到某个最近点或中心的距离。轮廓系数为

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \qquad S = \frac{1}{m}\sum_{i\in\mathcal{S}} s_i,$$

其中 $\mathcal{S}$ 为参与评价的样本集合，$m = |\mathcal{S}|$；全量评价时 $\mathcal{S}$ 包含全部样本。本题框架仅在评价子集满足 $2 \le K_{\mathcal{S}} < m$ 时计算并接受轮廓系数，其中 $K_{\mathcal{S}}$ 为子集实际覆盖的簇数；否则该指标记为未定义。单点簇内样本的轮廓系数按约定记为 0；若 $a_i = b_i = 0$，也按 0 处理。因此，“单点簇内样本记为 0”不表示所有样本各自成簇时仍有有效的总体轮廓系数。接近 1 表示分离清楚，接近 0 表示平均距离相近，负值表示平均而言更接近其他簇。

A.2 CH 与 DB 指数

CH（Calinski–Harabasz）指数定义为

$$\mathrm{CH} = \frac{B/(K-1)}{W/(N-K)}, \quad B = \sum_{q=1}^{K} n_q \|\mu_q - \bar{x}\|_2^2, \quad W = \sum_{q=1}^{K}\sum_{i\in C_q} \|x_i - \mu_q\|_2^2.$$

其中 C_q 为簇 q，$n_q = |C_q|$，μ_q 为该簇样本均值，$\bar{x}$ 为全体样本均值。本题框架仅在 $2 \le K < N$ 时计算并接受 CH；否则该指标记为未定义。若 W 恰为 0，则按接口约定返回 1.0。CH 越大，表示经自由度校正后，簇间离散相对于簇内离散越明显。

令 S_q 为簇 q 中样本到簇均值中心的平均欧氏距离，则 DB（Davies–Bouldin）指数为

$$S_q = \frac{1}{n_q}\sum_{i\in C_q} \|x_i - \mu_q\|_2, \qquad \mathrm{DB} = \frac{1}{K}\sum_{q=1}^{K} \max_{r\neq q} \frac{S_q + S_r}{\|\mu_q - \mu_r\|_2}.$$

它先找每个簇最易混淆的其他簇，再对这些相对散布程度取平均，因此越小越好。这里的 S_q 使用距离，不使用平方距离。本题固定近零判断的绝对容差为 10^{-8}，相对容差为 0，float32 与 float64 使用同一阈值：若所有 $S_q \le 10^{-8}$，或所有中心间距离均不超过 10^{-8}，返回 0；否则，仅将中心距离恰为 0 的簇对排除在最大值计算之外，正的中心距离仍按公式计算。实现应遵守 `code/q2_clustering/submission.py` 中的接口约定。

A.3 稳定性与标签评价的区别

稳定性可以用调整兰德指数（ARI）比较两次预测分区 $c^{(a)}$ 与 $c^{(b)}$；簇编号置换不影响比较，ARI 为 1 表示分区一致。多次运行时，可报告所有两两比较的均值、最小值及随机种子。重复初始化只检验初始化敏感性；重新抽取数据后拟合检验的是另一种稳定性，需要另行设计并明确比较样本。

用 ARI 或 NMI 比较预测分区与真实标签属于**外部评价**，与不依赖真实标签的预测分区稳定性含义不同。实验代码不读取隐藏标签来计算或优化外部指标；多数票 ACC 由课程组计算，定义见正文。轮廓系数不能写成分类准确率。

A.4 抽样、随机种子与公平比较

聚类拟合与评价抽样是两个步骤。全部 N 行参与聚类并获得簇编号；为了降低轮廓距离计算开销，可另外随机抽取 m 行进行评价。课程框架固定采用无放回抽样，轮廓距离在评价子集内部计算；抽样量和抽样种子可配置。CH、DB 使用全量样本。抽样量覆盖全部样本时即为全量轮廓评价。其它抽样或距离口径仅作为另行记录的扩展实验，不能与框架默认结果混写。

两类随机种子应分别记录。聚类种子控制初始中心等随机过程，可能影响分区；抽样种子控制选出哪些样本用于评价，不改变已完成的聚类。相同程序和输入下固定抽样种子可复现同一子集，更换种子通常得到另一批样本，两批可以重叠。

建议在报告中说明以下事项：

- 抽样量、是否无放回和抽样种子；完整抽样索引由框架保存在 `diagnostic_indices.npy`，无需粘贴进报告，请在本地保留至验收结束。候选方案宜使用同一子集，以减少比较中的额外随机差异。
- 距离在评价子集内部计算，还是以全量样本作为参考；两种口径的数值不可混写。
- 评价子集实际覆盖的簇数及全量最小簇大小。小簇可能完全缺席，因此不同 K 可能得到相同的抽样轮廓值；评价子集仅含一个簇时轮廓无定义，应明确记录。
- 如检验抽样敏感性，应固定已拟合分区、只改变抽样种子；如检验初始化敏感性，则固定评价子集、只改变聚类种子。两个因素同时改变时，无法把差异归因于其中一个。
- 报告重复运行的均值和标准差。随机种子间的标准差不是置信区间，不能据此直接宣称显著优于其他方案。
- 明确预处理、距离度量和评价空间。不同尺度或不同维度空间中的惯性不能直接比较绝对数值；轮廓、CH、DB 也受到几何空间变化影响。

二维 PCA 可以辅助展示，但需报告保留的方差比例；二维图不能代替原聚类空间的评价。指标间结论一致或不一致都应结合算法假设、簇大小和实验口径解释。

指标定义可参考 scikit-learn 的 轮廓系数、CH、DB与 ARI文档。